


MelodIA

Arquitetura do agente e uso responsável de LLM

Apresentação técnica · 8 minutos


GRUPO 8

Componentes atuais do sistema



LLM e Spotify são integrações opcionais; o núcleo local continua utilizável.

Fluxo completo de uma mensagem



Entrada e saída são registradas com identificadores técnicos, sem precisar guardar a conversa inteira.

FALLBACK EM CADA FRONTEIRA

O que é regra e onde o LLM entra

Determinístico

- valida o contrato
- filtra o catálogo
- calcula o ranking
- aplica diversidade
- monta fallback

LLM opcional

- converte texto livre em estrutura
- recebe contexto limitado
- devolve JSON esperado
- cai para regras se falhar

Decisão central: o LLM interpreta; o código decide.


Extração estruturada e contrato JSON

```
{  
  "generos": ["pagode"],  
  "mood": "animado",  
  "energia": "alta",  
  "limite": 3  
}
```

Validação antes de usar

- 1 campos conhecidos
- 2 tipos e limites
- 3 normalização de gênero
- 4 fallback seguro

Similaridade por cosseno e perfil do usuário



$$\cos(\theta) = (u \cdot \text{faixa}) / (|u| |\text{faixa}|)$$

O sistema compara vetores normalizados em memória. Não depende de um serviço externo de k-NN.

128.830 registros · 97.534 faixas únicas

Fallback, auditoria, diversidade e observabilidade

Fallback

regras locais
quando integração
falha

Auditoria

IDs, origem e
decisões do fluxo

Diversidade

limites para evitar
repetição

Observabilidade

tempo, erro e
estágio atingido


Falhar com clareza é parte da arquitetura.

OAuth, PKCE, tokens e privacidade



Sem autorização, a recomendação local continua disponível.

Notebook: perfil e correlação em dois passos



1

Perfil do conjunto

128.830 registros
97.534 faixas únicas
118 gêneros

2

Correlação

reexecutar apenas
as células selecionadas

PLANO B: IMAGEM JÁ GERADA

Testes, limitações e evolução

Evidências

testes do pipeline
validação do notebook
prévia da demo

Limitações

LLM e rede variam
OAuth exige
configuração
avaliação humana
pendente

Evolução

métricas de qualidade
feedback do usuário
testes de carga

O objetivo não é esconder limites — é controlá-los e medi-los.

Perguntas?