


Similaridade por cosseno

agente_conversacional/recomendacao/indice.py

Como o motor de recomendacao compara o perfil do usuario com cada faixa do catalogo

A ideia: comparar direcao, nao tamanho



$$\cos(\theta) = \frac{A \cdot B}{\|A\| \|B\|}$$

A, B vetores de 9 features de audio de duas faixas (ex.: perfil do usuario e uma faixa do catalogo)

θ angulo entre os vetores A e B

$A \cdot B$ produto escalar entre A e B (soma do produto das 9 componentes, feature a feature)

$\|A\|, \|B\|$ norma (comprimento) L2 de cada vetor

1 = idênticas em "formato" | 0 = sem relação | -1 = opostas

1. Dataset padronizado

9 features contínuas por faixa: danceability, energy, loudness, speechiness, acousticness, instrumentalness...

recomendacao/dataset.py

2. Padronizacao (z-score)

cada feature vira coluna _norm (mesma escala entre si)

FEATURES_AUDIO_NORM

3. Normalizacao L2 por linha

cada faixa vira um vetor unitario (feita 1x, na construcao do indice)

`matriz_unitaria = matriz / normas[:, None]`

4. Vetor da consulta normalizado

perfil do usuario / historico
tambem vira vetor unitario

`vetor_alvo / norma_alvo`

5. Produto escalar = cosseno

unitario · unitario = cos(θ) direto (sem dividir de novo)

`self._matriz_unitaria @ (vetor_alvo / norma_alvo)`

6. Ranking das faixas

maior score = mais parecida
top N via argpartition

`mais_similares(vetor_alvo, n)`

Por que cosseno (e não distancia euclidiana)? Duas faixas podem ter o "mesmo perfil sonoro" em proporcao mesmo com energia/volume absolutos diferentes — o cosseno ignora a magnitude do vetor e compara só a direcao.